

1조 프로젝트 소개

데이터 소개

데이터 탐색

분석 목표

모델 선정

평가 계획

1조

프로젝트 기획 발표

팀원 : 이진규, 이한웅, 최혜정

국민대학교, AI 응용시스템의 이해와 구축

Table of Contents

01	02	03	04	05
1조 프로젝트 소개 프로젝트 환경 및 팀원들을 소개하고, 주제를 선택한 이유를 전달합니다.	✦ 데이터 소개 및 탐색 프로젝트에 사용된 데이터에 대해서 소개합니다. 어떤 방식으로 수집되었는지, 어떤 기준으로 선택되었는지, 그리고 이 데이터가 어떤 목적을 가지고 만들어졌는지 설명합니다.	✦ 분석 목표 데이터 분석을 통해 이루고자 하는 목표를 발표합니다. 데이터 탐색 결과로 도출한 인사이트 또는 이해한 데이터를 바탕으로 목표에 맞게 파생변수를 생성합니다.	- 모델 선정 데이터에 따라 회귀, 분류, 클러스터링 등의 다양한 모델이 존재합니다. 데이터 및 프로젝트 주제와 적합한 모델을 탐색하고, 학습을 수행할 3가지 이상의 모델을 선정하여 학습계획을 수립합니다.	- 평가 계획 선정한 모델들의 성능과 적용 가능성을 평가계획을 수립합니다. 모델에 적합한 평가방법을 이용하여 학습된 모델을 평가하고, 결과를 비교하여 최종 모델을 결정하는 과정을 계획합니다.



Team Project " 롯데멤버스 고객 구매데이터를 기반으로 한 추천 알고리즘 적용 "



프로젝트 목표 : 군집 분석을 통해 비슷한 상품을 구매하는 개인들을 같은 군집으로 묶어서 추천 알고리즘 적용.

< 목표 적용 이론 > 군집 분석, 코사인유사도, 행렬분석

< 프로젝트 환경 >

-  python™
-  구글 Colab
Google Colaboratory



1조 | 팀원소개



아이디어뱅크

이진규


> 다양한 아이디어로 의견 공유로
프로젝트를 성공적으로 이끔
> 관심분야: 임상 및 의료 서비스



소통창구, 의견화합

이한웅

> 소통과 의견을 조율하고 전문성으로
프로젝트를 이끔
> 관심 분야: 건강/운동 산업 관련



응원자

최혜정

> 열심히 응원하는 팔로워,
프로젝트의 마무리 도움
> 관심 분야: 게임 및 이상감지

고객 구매데이터를 기반으로 추천시스템 적용



- [1] 롯데멤버스는 꾸준히 고객 구매 데이터를 기반으로 한 공모전을 주최해 옴.**
 - 2022년 6월, 7회까지 빅데이터 경진대회가 개최됨.
 - 기업 측면에서 중요한 데이터로 흥미를 가지고 데이터를 탐색함.
- [2] 디지털 전환 가속화의 핵심, 인공지능 기술의 활용.**
 - 평소에 관심을 가지고 있던 인공지능 기술을 데이터에 접목해보고자 함.
- [3] 추천 알고리즘을 통한 솔루션 마련하고자 함.**
 - 추천 시스템을 통해 기존 고객 편의성과 만족도를 높임.
 - 신규고객에게도 추천 시스템 활용하여 구매 만족도를 높이길 기대함.

롯데멤버스 데이터

(구분)	(속성)
고객 Demo	고객번호, 성별, 연령대, 거주지 (19383, 4)
구매내역 TR	제휴사, 분류, 고객번호, 구매일, 구매금액 등 (28593030, 10)
상품분류	제휴사, 대분류코드, 중분류코드, 소분류코드 등 (4386, 6)
경쟁사 이용	고객번호, 제휴사, 경쟁사, 이용년월 (28159, 4)
멤버십여부	고객번호, 멤버십명, 가입년월 (7456, 3)
채널이용	고객번호, 제휴사, 이용횟수 (8824, 3)

데이터 확인

- ☒ 고객번호로 매핑하여 고객별 구매건수, 구매금액 등 탐색 가능
- ☒ 제휴사와 분류코드 매핑하여 고객별로 주요 구매상품 확인 가능
- ☒ 고객 구매활동 뿐만 아니라 채널이용, 멤버십 여부, 경쟁사 이용을 통해 고객 특성 확인 가능


데이터 탐색 목적

- 다양한 파생변수 생성하여 고객분류분석
- 데이터 전처리 및 가공하여 추천시스템 적용에 알맞은 형태로 변환


데이터 탐색 (1)

고객 분포 고객 DEMO) 성별, 연령대

성별 per



연령대 per



- 고객 DEMO 데이터를 보면 여성고객이 82%로 많은 비율을 차지하고 있음.
- 연령대는 45~49세가 21%로 가장 많았고 그 전후 구간을 합쳐서 전체 고객의 56% 임.
- 남,여 연령대 비율은 유사함.
- 거주지 데이터는 너무 다양하고 특색 없어보여서 이용하지 않음.

데이터 탐색 (2)

고객 구매데이터 특성 월별구매건, 구매금액, 구매간격 확인




*구매건수 유사함

구매금액 증감

+ 3%

제휴사별



전체		2014년		2015년	
제휴사	구매 1건당 평균금액	제휴사	구매 1건당 평균금액	제휴사	구매 1건당 평균금액
A	89,222	A	86,983	A	91,428 (+)
B	8,339	B	8,864	B	7,860 (-)
C	5,337	C	5,162	C	5,507 (+)
D	8,495	D	8,849	D	8,316 (-)


→ A제휴사의 상품의 가격대가 높음. A제휴사를 주로 이용하는고객과 B, D제휴사, C제휴사 3가지로 분류하여 선호제휴사에 대한 파생변수 생성이 가능해보임.

→ 구매금액이 2014년보다 2015년 약 3% 증가했는데, A제휴사의 구매상품 평균 금액이 오른것이 영향이 있어 보임.

데이터 탐색 (2)


고객 구매데이터 특성 월별구매건, 구매금액, 구매간격 확인

제휴사별



→ 제휴사별 1회 방문시 평균 구매금액은 A제휴사와 C 제휴사는 증가했고, B 제휴사와 D 제휴사는 감소한 것을 알 수 있음.

제휴사별 연도별 중복이용 현황




*증감율

-0.3%	-0.8%	-0.7%	0.0%	-4.9%	-0.9%	-1.6%	0.1%	0.0%	0.7%	4.0%	0.5%	0.2%	3.4%
-------	-------	-------	------	-------	-------	-------	------	------	------	------	------	------	------


데이터 탐색 (2)

고객 구매데이터 특성 월별구매건, 구매금액, 구매간격 확인

월별



요일별



구매 특성 확인



- 10,11,12월의 구매데이터를 보면 구매건수는 다른 월보다 비교적 적은데, 구매금액 합계는 높은 특성이 있음.
- 요일별로 구매정보를 확인했을 때, 일요일과 토요일에 구매건수에 비해 금액이 높은 특성이 보임.

데이터 탐색 (3)

기타 탐색 결과

상품 분류 / 멤버십 여부 / 채널이용

상품분류




- 각 제휴사의 중분류 마다 속하는 소분류는 3개~70개 이상으로 다양한 범위로 구성되어 있음.
- 제휴사별 소분류 개수 확인 결과 B 제휴사의 소분류가 가장 많은 것을 알 수 있고, 소분류는 너무 많아서 대분류 혹은 중분류를 이용할 수 있을 것으로 보임.


데이터 탐색 (3)

기타 탐색 결과 상품 분류 / 멤버십 여부 / 채널이용

멤버십 여부



채널이용



- 하이마트 멤버십을 가입한 고객이 멤버십 가입고객중에 가장 많고, 제휴사별 채널 이용 데이터는 B제휴사의 모바일/앱 채널 이용이 많은 것을 확인할 수 있음.
- 멤버십 여부나 채널 이용에 대한 고객 정보는 전체 고객의 약 35%로 유의미한 정보인지 판단 미정.

분석 목표

| 타겟 설정

1) 군집화

군집분석으로 고객 특성에 맞게 군집 생성

> 고객 특성을 파악하여, 군집분석을 수행하고 맞춤형 군집을 생성합니다. 이를 통해, 고객들의 다양한 관심사 및 욕구를 파악하고, 그에 따라 마케팅 전략 또한 수립할 수 있습니다.

2) 개인별 아이템 추천

고객특성 및 구매 패턴 변수를 활용하여 개인별 적합한 아이템을 추천

> 머신러닝 알고리즘을 활용하여 개인화된 추천 시스템을 구축합니다.. 추천 시스템은 각 고객의 취향과 관심사를 파악하여 개인별로 적합한 아이템을 추천합니다. 군집별로 고객의 만족도 상승을 위한 최적의 추천 방식을 결정합니다.

파생변수 생성

다양하게 도출한 변수들 중 의미있는 변수 선정 및 생성



- 월별 구매빈도, 구매금액, 구매건수 이용하여 도출
- 상품 카테고리 정보
- 이외의 이용 가능한 다른 변수들 (고객정보, 멤버십유무, 구매랭킹)

| 전처리





Standardization, Normalization, Label encoding, One-Hot encoding 등 변수 scaling 또는 encoding 고려 필요

모델선정

- 군집분석 : 개인들을 같은 군집으로 묶어서 적절하게 상품추천을 적용하기 위함.

K-means (군집간의 거리를 이용하여 클러스터링)

Demonstration of the standard algorithm



1. K설정

K는 중심점이자 cluster의 개수

2. cluster 부여

k개의 중심점(동그라미)과 개별 데이터(네모)간의 거리를 측정하여 가까운 중심점으로 데이터 부여

3. 중심점(centroid) 업데이트


할당된 데이터들의 평균값(mean)으로 새로운 중심점(centroid)을 업데이트

4. 최적화

2,3번 작업을 반복적으로 수행, 변화 없을 경우 작업 중단.

- 사용이 쉽고 간결하여 일반적인 군집화에 가장 많이 사용됨.
- 속성의 개수가 많을 시 군집의 정확도가 많이 떨어지고, 반복 횟수가 많을 경우 시간이 오래 걸리는 단점이 있음.

DBSCAN (밀도 기반 클러스터링)




→ 처음에 그룹의 수(k)를 설정하지 않고 자동적으로 최적의 그룹 수를 찾아나감.

- ① 점 p에서 부터 거리 e(epsilon)내에 점이 m(minPts)개 있으면 하나의 군집으로 인식함.
- ② 회색점 P2의 경우 점 P2를 기반으로 epsilon 반경내의 점이 3개 이기 때문에, minPts=4에 미치지 못하여 군집의 중심이 되는 core point는 되지 못하지만, 앞의 점 P를 core point로 하는 군집에는 속하기 때문에 이를 border point (경계점)이라고 함.
- ③ P3를 중심으로 하는 반경내에 다른 core point P가 포함이 되어 있는데, 이 경우 core point P와 P3는 연결되어 있다고 하고 하나의 군집으로 묶이게 됨(④).

모델선정 - 추천 시스템

추천시스템 소개



추천이란?


- 선호도 및 과거 행동을 토대로 고객에게 적합한 상품 추천.
- 개개인의 선호도를 고려한 추천과 이를 구매로 연결시키기 위한 목적.

협업 필터링(CF)

- 사용자의 취향을 고려한 추천시스템 개발
- 특정 아이템에 대해 비슷한 취향을 가진 사람들은 다른 아이템 또한 비슷한 취향을 가질 것이라고 가정
- 특정 사용자와 취향이 비슷한 집단 (유사 집단) 의 취향을 기반으로 아이템 추천


사용자 기반 협업 필터링

(사용자(고객) 간의 유사성을 측정)



아이템 기반 협업 필터링

(고객 선호상품과 다른 상품들간의 유사성을 측정)



- UBCF의 장점은 각 사용자별로 맞춤형 추천을 하기 때문에 데이터가 풍부한 경우 정확한 추천이 가능.
- BCF의 장점은 정확도는 떨어지지만 사용자별로 따로따로 계산을 하지 않기 때문에 계산이 빠르다는 장점.

유사도 지표

사용자 또는 아이템간 유사도를 구하기 위해 유사도 지표를 활용

✓ 유클리디안 유사도

- 문서간의 유사도를 계산

	과일이	길고	노란	먹고	바나나	사과	싫은	저는	좋아요
문서1	0	0	0	1	0	1	1	0	0
문서2	0	0	0	1	1	0	1	0	0
문서3	0	1	1	0	2	0	0	0	0
문서4	1	0	0	0	0	0	0	1	1

```
1 from sklearn.metrics.pairwise import euclidean_distances
2 1 / (euclidean_distances(countvect_df, countvect_df) + 1e-5)
```

array([[1.00000000e+05, 7.07101781e-01, 3.33322222e-01, 4.08246624e-01],
[7.07101781e-01, 1.00000000e+05, 4.47211596e-01, 4.08246624e-01],
[3.33322222e-01, 4.47211596e-01, 1.00000000e+05, 3.33322222e-01],
[4.08246624e-01, 4.08246624e-01, 3.33322222e-01, 1.00000000e+05]])

유클리디안 유사도 = 1 / (유클리디안 거리 + 1e-05)

$$\|p - q\| = \sqrt{(p - q) \cdot (p - q)} = \sqrt{\|p\|^2 + \|q\|^2 - 2p \cdot q}$$

$$\frac{1}{\sqrt{1^2 + 1^2 + 1e-5}} = 0.707$$

[장점]

- 계산하기가 쉬움

[단점]

- p와 q의 분포가 다르거나 범위가 다른 경우에 상관성을 놓침

✓ 코사인 유사도

- 문서간의 유사도를 계산

	과일이	길고	노란	먹고	바나나	사과	싫은	저는	좋아요
문서1	0	0	0	1	0	1	1	0	0
문서2	0	0	0	1	1	0	1	0	0
문서3	0	1	1	0	2	0	0	0	0
문서4	1	0	0	0	0	0	0	1	1

```
1 from sklearn.metrics.pairwise import cosine_similarity
2 cosine_similarity(countvect_df, countvect_df)
```

array([[1., 0.66666667, 0., 0.],
[0.66666667, 1., 0.47140452, 0.],
[0., 0.47140452, 1., 0.],
[0., 0., 0., 1.]])

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

$$\frac{1 + 1}{\sqrt{1^2 + 1^2 + 1^2} \cdot \sqrt{1^2 + 1^2 + 1^2}} = 0.6667$$

[장점]


- 벡터의 크기가 중요하지 않은 경우에 거리를 측정하기 위한 메트릭으로 사용. (예 : 문서내에서 단어의 빈도수 - 문서들의 길이가 고르지 않더라도 문서내에서 얼마나 나왔는지라는 비율을 확인하기 때문에 상관없음.)

[단점]

- 벡터의 크기가 중요한 경우에 대해서 잘 작동하지 않음

✓ 유클리디안 유사도 vs 코사인 유사도

- 문서간의 유사도를 계산 (유클리디안 유사도)



→ 유클리디안은 가장 가까운 점을 찾기에 파란색의 "young"이 가장 유사한 벡터. 하지만, 코사인 유사도의 경우 크기가 아닌 방향성을 보기에 "mid" 혹은 "adult"가 가장 유사하게 됨.
즉, 유사도 계산방법의 선택도 현재 가지고 있는 데이터에 따라서 다르게 적용해주는 게 중요

→ 상관계수, 타니모토 계수 등 다양한 유사도 지표가 있음.

행렬 분해(MF알고리즘)

선형대수학의 SVD(Singular Value Decomposition)을 응용하여 나온 방법론

M개의 사용자(User) 행과 N개의 아이템(Item) 열을 가진 평점 행렬 R은 M X N 차원으로 구성되며, 행렬 분해를 통해 사용자-K 차원의 잠재 요인 행렬 P (M X K 차원)와 K 차원의 잠재 요인—아이템 행렬 Q.T (K X N 차원)으로 분해될 수 있음.

R (4 X 5)					
	item 1	item 2	item 3	item 4	item 5
User1	4		2		
User2		5	?	3	
User3			3	4	
User4			1	2	4
User5	5	2			

=

P (4 X 2)		
	Factor 1	Factor 2
User1	0.94	0.96
User2	2.14	0.08
User3	1.93	1.79
User4	0.58	1.59

×

Q.T (2 X 5)					
	item 1	item 2	item 3	item 4	item 5
Factor1	1.7	2.3	1.41	1.36	0.41
Factor2	2.49	0.41	0.14	0.75	1.77

- R 행렬의 u행 사용자와 i열 아이템 위치에 있는 평점 데이터를 r(u,i)라고 하면, P행렬과 Q.T 행렬의 곱을 통해 평점데이터를 유추 가능.

예측결과 : $2.14 \times 1.41 + 0.08 \times 0.14 = 3.02$

Matrix Factorization-based algorithms


```
from surprise import SVD
# Use the famous SVD algorithm.
algo = SVD()
```

Alternating Least Squares(ALS)

MF에 사용되는 사용자와 아이템 잠재벡터 이렇게 두 종류의 파라미터를 서로 번갈아가면서 업데이트를 한다는 것. 즉, **P와 Q 중 하나를 고정**해놓고 다른 하나를 업데이트하는 방식. 이는 선형회귀 문제가 되어 최소제곱법(OLS)을 통해 최적의 값 도출.

*OLS(Ordinary Least Squares) : 잔차제곱합 최소화하는 가중치를 구하는 방법

- 4개 과정이 순차적으로 진행
- 1) 초기 아이템, 사용자 행렬을 초기화
- 2) 아이템 행렬을 고정하고 사용자 행렬을 최적화
- 3) 사용자 행렬을 고정하고 아이템 행렬을 최적화
- 4) 위의 2, 3 과정을 반복



→ 우리는 Y를 고정시키고 X를 optimize한 다음, X를 고정시키고 Y를 optimize할 것이고 이를 수렴할 때 까지 반복하는 것.

Using prediction algorithms

```
from surprise import KNNBasic
bsl_options = {"method": "als", "n_epochs": 20,}
sim_options = {"name": "pearson_baseline"}
algo = KNNBasic(bsl_options=bsl_options, sim_options=sim_options)
```

컨텐츠 기반 필터링

- 사용자의 취향을 고려한 추천시스템 개발
- 특정 아이템에 대해 비슷한 취향을 가진 사람들은 다른 아이템 또한 비슷한 취향을 가질 것이라고 가정
- 특정 사용자와 취향이 비슷한 집단 (유사 집단) 의 취향을 기반으로 아이템 추천




항목 자체를 분석하는 것이 포인트
(아이템 속성 분석)

- ① 아이템을 잘 표현할 수 있는 속성 및 아이템마다 각 속성에 해당하는 값이 존재해야 함. 콘텐츠에 대한 연구필요.
- ② 키워드 분석은 각 텍스트 아이템에서 키워드를 추출한 뒤(대표적으로 TF-IDF), 아이템간의 키워드를 비교하여 유사도를 계산
- ③ 아이템-키워드 행렬을 통해 아이템간의 유사도를 계산

- 하나의 단어가 다양한 의미를 가지는 경우 실제로 유사하지 않은 아이템이 추천 될 수 있음.
- 다양한 단어로 표현되지만 실제로 같은 의미를 가지는 경우에는 내용적으로 유사한 아이템일 지라도 유사도가 낮으므로 추천 리스트에서 누락될 수 있음.
- 한정된 메타정보로 사용자와 상품의 프로파일 함축 불가하는 한계점이 있음.

내용 기반 필터링 (Content-based Filtering)



모델 평가


군집모델 평가

1. Elbow Method

- > 군집내 변동성이 급감하는 군집 개수를 찾는 것
- > 군집간 분산(BSS)과 전체 분산(TSS = BSS + WSS)의 비율이 고려됨.
intertia(클러스터 샘플 사이의 거리)의 변화를 관찰하여 최적의 군집수 찾는 방법.

WSS (Within cluster Sum of Squares)

$$= \sum_{j=1}^K \sum_{i \in c_j} d(x_i, c_j)^2$$



SSE(Sum of squared error)값을 클러스터의 개수를 두고 비교를 한 그래프를 통해 급격한 경사도를 보이다가 완만한 경사를 보이는 SSE값을 보이는 부분(팔꿈치)에 해당하는 클러스터를 선택하는 기법을 통해 최적의 K값을 선택할 수 있음.

2. Silhouette method


- > 군집별 데이터가 할당된 군집 내 데이터와 얼마나 가깝게 군집화 되어있 는지, 그리고 다른 군집에 있는 데이터와는 얼마나 멀리 분리되어 있는지를 수치로 나타냄.

$$s(i) = \frac{b(i)-a(i)}{\max(a(i),b(i))}$$

- > -1에서 1 사이의 값, 0에 가까울수록 군집화 잘된 것.

3. Dendrogram

- > 클러스터링 결과 시각화 그래프
- > 합당한 군집별 색이 다르게 표현됨.




모델 평가

추천시스템 평가




1. Precision/Recall@K

- Precision@K : 우리가 추천한 K개 아이템 가운데 실제 유저가 관심있는 아이템의 비율
- Recall@K : 유저가 관심있는 전체 아이템 가운데 우리가 추천한 아이템의 비율




2. Hit Rate@K

- Hit Rate는 전체 사용자 수 대비 적중한 사용자 수를 의미(적중률)




3. NDCG@K (Normalized Discounted Cumulative Gain)

- Top K개 아이템을 추천하는 경우, 추천 순서에 가중치를 두어 평가



- 1) Relevance란, 사용자가 특정 아이템과 얼마나 관련이 있는지를 나타내는 값
- 2) CG(Cumulative Gain)는 추천한 아이템의 Relevance 합으로 순서를 고려하지 않은 값
- 3) Discounted Cumulative Gain (DCG)는 CG에 순서에 따른 할인 개념을 도입한 값, 사용자별로 추천 아이템의 수가 다른 경우 정확한 성능 평가가 어렵다는 한계점이 존재
- 4) DCG의 한계점을 보완하기 위해 DCG에 정규화를 적용한 것이 NDCG

프로젝트 결과



활용 예시

- 배너를 통한 추천상품 노출


- 구매율 높은 상품
- 사용자와 구매패턴이 유사한 다른 사용자가 구매한 상품

- 고객맞춤 뉴스레터 발송


- 구매빈도 높은상품 할인쿠폰 발송
- 구매관련상품 신제품 알림
- 기념일 축하쿠폰
- 할인 행사 정보

- Prevent**
고객 만족도를 높여 기존 고객층을 유지하고 고객 이탈 예방 및 새로운 고객층의 확보를 시도하는데 도움을 준다.
- Customer**
유사한 상품을 자주 구매하는 고객에게 해당 상품의 쿠폰을 제공하는 등 개인맞춤 서비스를 제공하도록 활용할 수 있다.
- Marketing**
고객이 구매할 확률이 높은 상품을 추천시스템을 통해 선별하고 뉴스레터에 이를 활용하여 마케팅 전략을 세울 수 있다.

추천알고리즘 활용예시



아마존 상품상세화면




쿠팡 상품상세화면

→ 아마존과 쿠팡 모두 Collaborative Filtering, 즉 과거 데이터로부터의 '유사도' 패턴을 기반으로 미래의 선호를 예측하는 협업필터링 방식으로 추천해왔었음.

→ '다른 고객이 함께 본 상품'과 같은 대체재와 '다른 고객이 함께 구매한 상품'과 같은 보완재를 추천

→ 실시간 개인화



Thank you

✉ isdl15980@gmail.com
jinkyu.lee@gmail.com
qwe121292@gmail.com



국민대학교 소프트웨어융합대학원
AI 응용시스템의 이해와 구축

